


Breve *recap* di algebra lineare per
Machine Learning / Deep Learning
(*per informatici*)

La rappresentazione vettoriale dei dati

$P=2$

X_1 = Età della persona
 X_2 = Altezza della persona

Mario Rossi: età=35, altezza=175




Da un punto di vista informatico, Mario Rossi è una riga della tabella, da un punto di vista matematico (algebrico) Mario Rossi è un PUNTO in uno spazio bi-dimensionale ($p = 2$). Tale potente astrazione permette anche di gestire immagini, audio e testi (non-strutturati).

	Età	Altezza
Mario Rossi	35	175

La vista geometrica di un dataset p-dimensionale

Le dimensioni (assi) dello spazio $\mathcal{R}^p = \mathcal{R}^6$ sono qui le colonne del dataset (X_1, X_2, \dots, X_6), le componenti di ogni vettore sono i valori delle varie righe

$p=6$



Disclaimer: gli assi dovrebbero essere ortogonali tra loro, tutte le proiezioni dovrebbero essere ortogonali agli assi (non facile da disegnare in uno spazio \mathcal{R}^6 !)

Legenda:



Un vettore nello spazio \mathcal{R}^6 , cioè una riga del dataset (unità statistica)



La componente del vettore rispetto alle varie dimensioni.

Segnale vs rumore

$$Y = f(\underline{X}) + \varepsilon$$



$$\hat{Y} = \hat{f}(\underline{X}^*)$$

Fittare («adattare») un modello (predittivo, in questo caso) ai dati significa stimare dai dati la funzione \hat{f} (il modello).

In questo fenomeno, ovvero nel **processo generativo dei dati** che è ad esso sotteso, e che in genere NON conosciamo, è predominante la parte sistematica (il segnale) o la parte casuale (il rumore)?

X-bar = vettore delle vere variabili esplicative del fenomeno

X-bar* = vettore delle variabili esplicative disponibili (eliminarne parti per evitare overfitting, cioè modelli troppo complessi, oppure aggiungerne, se si hanno le conoscenze di business).

Abbiamo a disposizione un campione di training che riporta le vere Y e il vettore X-bar campionato

I due spazi del Machine Learning

\mathcal{R}^p : lo spazio delle variabili

(ML non-supervisionato)

\mathcal{R}^{p+1} : lo spazio completo

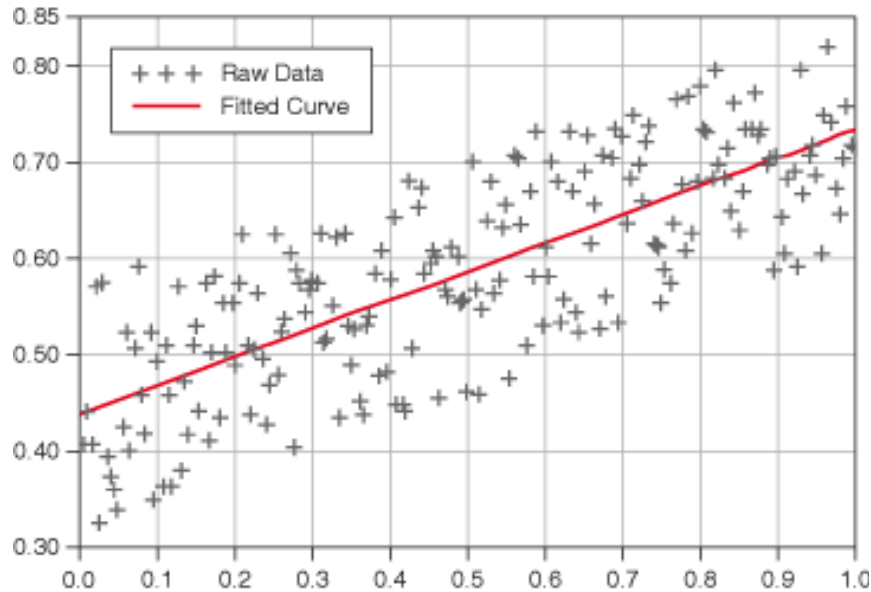
(ML supervisionato)




in questo spazio si trova
 $f(\underline{X})$, ma non la soluzione
 $\underline{\theta}^* \in \mathcal{R}^\theta$ del modello di
ottimizzazione - vedi dopo

Il fitting lineare dei dati nel ML supervisionato in \mathcal{R}^{p+1}

Approssimazione numerica




\mathcal{R}^{p+1}




Uno spazio lineare (retta, piano, iperpiano) è definito da una **combinazione lineare** delle variabili: $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$. I coefficienti del modello (reale e stimato) sono in genere espressi tramite lettere greche.

Decision Boundary

\mathcal{R}^p





Linearly separable dataset



Linearly inseparable dataset

Il fitting non-lineare dei dati nel ML supervisionato \mathcal{R}^{p+1}

Approssimazione numerica



Decision Boundary

L'inferenza

Nel ML supervisionato, la funzione reale, quella che genera la popolazione e che si identifica con $f(\underline{X})$, è **stimata (approssimata)** tramite i dati disponibili, sui quali si **fitta** una funzione $\hat{f}(\underline{X})$.

Questo processo è detto **inferenziale**, perché «induce» (aristotelicamente) una conoscenza generale da una particolare (cioè dal campione alla popolazione).

La funzione f è la parte deterministica del modello, il quale è formato anche da una parte stocastica (l'errore ε).

Lo spazio θ dei parametri

Dietro molti problemi di ML, supervisionati oppure no, c'è un problema di ottimizzazione:

$$\underline{\theta}^* = \underset{\underline{\theta}}{\operatorname{argmin}} \mathcal{L}(\underline{x}, \underline{\theta})$$

dove $\mathcal{L}(\underline{x}, \underline{\theta})$ è la funzione di costo (*loss function*)

Lo spazio nel quale si opera è \mathcal{R}^θ , lo spazio dei parametri del modello, cioè le variabili della loss function da minimizzare.

Anche le reti neurali profonde sono dentro questa framework concettuale.